

牙菌斑 SERS 数据集成果总结

Phase3A_v1.0 | 患者级监督学习数据集 | 二分类: 阴性=0, 阳性=1

患者数

52

临床独立样本单位

光谱数

1970

训练实例可使用单条 spectrum

谱维度

732

每条光谱 732 个 Raman shift 点

Raman shift

395.11-1840.62 cm^{-1}

来自 wavenumber.npy

核心贡献

1. 将原始 CSV SERS 光谱整理为统一的建模张量: $X_{\text{spectra}} = (1970, 732)$, 同时保留 $X_{\text{raw_spectra}}$ 。
2. 明确患者级标签继承规则: 每条 spectrum 的标签来自其所属患者, 避免人为给单条谱重复定义标签。
3. 固定患者级 train/val/test 划分, 同一患者全部光谱只进入一个集合, 防止患者级数据泄露。
4. 同时记录 patient_index、patient_uids、spectrum_ids, 支持 spectrum-level 训练和 patient-level 评估。
5. 暴露并量化类别不平衡与患者光谱数不均衡, 为后续 patient-balanced loss 和 patient aggregation 提供依据。

数据集定义


$$D = \{ (x_i, y_p, p_i) \}$$

x_i : 第 i 条 SERS 光谱 | y_p : 患者标签 | p_i : 所属患者 ID

训练时可使用单条 spectrum 作为 instance; 但验证和测试必须回到 patient-level prediction, 因为临床决策单位是患者。

数据集构造流程

从原始 SERS CSV 到可训练、可审计、患者级无泄露的数据集



严谨性约束

Normalization: SNV 是逐条光谱独立操作, 不利用标签、患者分组或全局统计量。


Split first: 所有光谱扩展和训练实例构造都必须在患者级划分之后进行。

Evaluation unit: 任何最终性能结论应基于 patient-level aggregation, 不能只报告 spectrum-level 指标。


数据组成与不平衡结构

关键结论: 数据是患者级独立, 但光谱数在类别和患者之间明显不平衡。


患者级类别分布




光谱级类别分布



每位患者贡献的光谱数





患者光谱数排序图



患者级划分与无泄露约束

seed=42, split unit=patient, ratios=60%/20%/20%; 同一患者的所有光谱只进入一个集合。



Train patients
31 patients
18 阳性 / 13 阴性
1197 spectra

Validation patients
10 patients
6 阳性 / 4 阴性
381 spectra

Test patients
11 patients
7 阳性 / 4 阴性
392 spectra


Leakage check: patient overlap = 0

严格规则: 不能用 spectrum-level random split。否则同一患者的相似光谱可能同时出现在训练和测试中, 导致性能虚高。


光谱表示与使用边界

本页展示 raw spectrum 与 SNV spectrum 的形态, 并说明该数据集在后续建模中的正确使用方式。

Raw spectra: 类别均值示例



SNV spectra: 建模输入示例



后续建模建议

推荐使用	spectrum-level training + patient-level aggregation
推荐指标	AUC, Acc, BalAcc, Sens, Spec, Brier, ECE
推荐权重	patient-balanced loss

风险与限制

禁止	spectrum-level random split
谨慎	仅报告单次 seed 结果
限制	无外部验证; 当前为内部患者级验证数据集

NaN/Inf check: NaN=False, Inf=False. Unique patients=52, unique spectra=1970.